RescueMind：現地で「目で確かめてから」届ける災害物資ロボット

最新のローカルVLM（Qwen3.5-9B / V100）× ROS 2 Jazzy × Gazebo Harmonic ― 誤った物資を届けず、無ければ探し、危険なら止まる

項目	内容
提出者	omnicampus アカウント：tetsutetsu
コード	https://github.com/fe2131-art/rescue-mind
動画	YouTube（タイトル：PAI最終課題_tetsutetsu）。走行8倍速・確認動作3倍速・AI判断の瞬間は等速（倍速は動画内に常時表示）。日本語ナレーション（VOICEVOX:四国めたん）
範囲	物資の現物確認と避難所Bへの接近まで。本資料の「配達」はこの意味で、物資の把持・荷降ろし・受け渡しはシミュレーションしていない
使用ツール	ROS 2 Jazzy / Gazebo Harmonic（Docker・EGLヘッドレス描画）/ PyTorch 2.8 + Transformers 5.20 / Tesla V100 32GB（sudo不要）
AIの活用	① 自然言語指示の理解（ローカルLLM）② 搭載カメラ画像による現物・危険の確認（ローカルVLM、選択肢の確率で判断）③ 現場の人への日本語状況報告
主結果	事前登録した42試行の閉ループ評価で期待どおりの行動 42/42、誤った物資・火災のある拠点からの配達（誤許可）0 件、判断遅延の中央値 3.1 秒。v3.5の評価E（試行ごとにランダムな世界、60試行）で 60/60、誤配達 0 件。v3.6（小さな火への対策）の評価G（新しい世界の対比較）では、3視点（正面・左右0.4 m）のどれかで火が見えた16世界で、火があるのに配達した回数が 11 → 1（McNemar正確検定 p=0.002）、火の無い世界での誤停止 0/8。未使用の画像600枚（T1）では、拒否すべき非火災画像 332 枚の誤許可 0 件、小さく写った火の見逃しが残る弱点

審査基準との対応

審査基準	本作品での取り組み	根拠（本資料の節・リポジトリ）
創造性	「運ぶAI」ではなく「間違えたら動かないAI」。現物確認・別拠点の探索・火災時の停止・日本語の状況報告を1つの閉ループに統合	1章, 3章, 4.2章（評価E）, 動画デモ2・3
技術力	選択肢の確率によるVLM判定、最新モデルの調査と公平比較、Gazebo真値による独立監査、独立速度ガード、事前登録した閉ループ評価（D・E・F・G）と未使用画像の評価（T1・T2）、弱点（小さな火）の特定と、問い方の改良・2つ目のAI・横から見直す能動知覚による段階的な対策（対比較の検定つき）、推測航法ドリフトの原因特定	2章, 4.1–4.4章, 5章（H・J・Z・P・R）, 6章, docs/IMPROVEMENT_LOG.md
実用性	オフライン・単一GPU・Apache-2.0、在庫と現物のずれへの対応、人への報告と判断の委譲、Docker（sudo不要）で再現可能。ランダム化した世界での評価Eと反事実との比較で、回復探索の実効果を示した	4.2・4.4章, 8章, 11章, README
表現力	実レンダリング映像にAR軌跡・確率バー・ロボットの報告を重ねた日本語ナレーション付き動画、全体フロー図・設計判断記録	4.2–4.4章（区間推定・検定つきの表）, 10章, docs/ARCHITECTURE.md

1. 課題の概要と目的

災害時の物資配送では「在庫表では水があるはずの棚に救急箱が置かれていた／空だった」という情報と現物の食い違いや、現場の危険（火災）が起こる。指示どおり機械的に運ぶロボットは、誤った物資を届けたり危険な場所に留まったりする。本作品では、自然言語で依頼を受けた差動二輪ロボットが物資拠点へ自律移動し、その場で静止して搭載カメラで現物を確認する。ローカルVLMが依頼物資を高い確信で確認したときだけ避難所Bへ向かい、物資が違えばもう一方の拠点を探して正しい物資を届け、火災を見たら探索せずに停止して、見たものを日本語で報告する。

狙いは「AIに運ばせる」ことではなく、AIの判断が間違っていればロボットが動かないことを、ログと物理シミュレータの真値で第三者が検証できる形にすることである。ロボットは物資の把持・運搬は行わない（現物確認と避難所への接近までを対象とし、配達完了とは表現しない）。

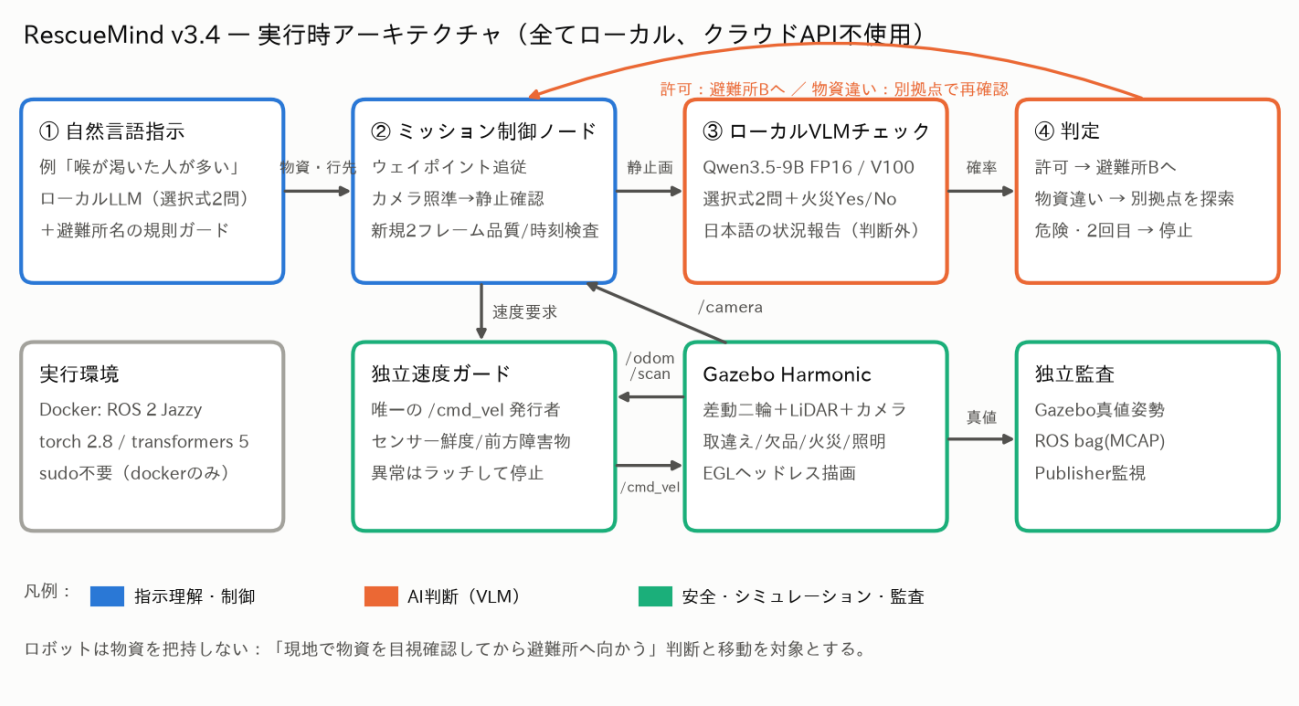


図1 実行時アーキテクチャ。全推論はローカルGPUで実行（クラウドAPI不使用）。詳細なフロー図は docs/ARCHITECTURE.md。

2. AIの活用と工夫

2.1 現地確認：文章を生成させず「選択肢の確率」で判断する

VLMに選択式の質問（台の上は 水／救急箱／なし・その他）を2問、選択肢の順序を入れ替えて出し、回答文字の次トークン確率を1回の順伝播で読む。2問とも依頼物資が最大かつ確率0.50以上（τ_s）、火災・煙のYes/No 質問が0.05未満（τ_h、v3.6。v3.4までは0.50）のときだけ許可する。引継ぎ版の「JSONを自由生成させる」方式は、実画像で96応答中21件が解析不能、空の台で「水がある」と幻覚した。選択肢方式では解析不能0、開発画像で 37/48 → 48/48 となった。

2.2 モデルの調査と選定（最新世代への更新）

当初のQwen2.5-VL-3B（2025年1月・研究用途ライセンス）から、2025〜2026年の新世代（Qwen3-VL-8B、Qwen3.5-4B/9B、いずれもApache-2.0）を調査した。V100（FP16のみ）向けに torch 2.8＋transformers 5.20 の実行環境を用意し、同じ開発データ・同じ手順で比較。1回目は3B向けに調整したプロンプトのため新モデルが救急箱を「その他」と答える誤りが多発し、選択肢に外見と用途を併記したモデル非依存のプロンプトで公平に再比較した。

モデル	公開	視覚判定（176枚）	状況説明（128枚）	指示理解（開発40文）	1問の遅延
Qwen2.5-VL-3B	2025-01	176/176 (FA 0, FD 0)	84/128	31/40 (unsafe 0)	0.76 秒
Qwen3-VL-8B	2025-10	176/176 (FA 0, FD 0)	120/128	38/40 (unsafe 2)	0.41 秒
Qwen3.5-4B	2026-02	175/176 (FA 1, FD 0)	125/128	35/40 (unsafe 2)	0.94 秒
Qwen3.5-9B	2026-02	176/176 (FA 0, FD 0)	125/128	35/40 (unsafe 0)	0.98 秒

誤許可（視覚）と危険な誤受理（指示）がともに0だった唯一の新世代モデル Qwen3.5-9B（2026年2月）を採用した。状況説明の正確さは 84 → 125/128 に向上。

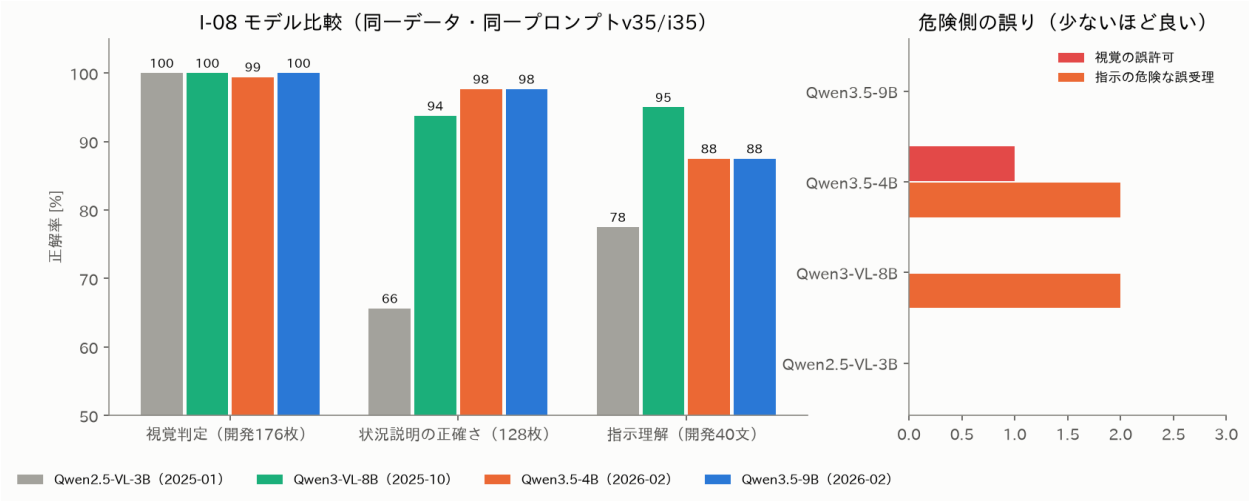


図2 モデル比較（開発データ）。右：危険側の誤り。評価用データはモデル選定に使っていない。

2.3 自然言語指示の理解

同じローカルモデルに「物資は？」「届け先は？」の選択式2問を出して解釈し、明示的に別の避難所名がある指示は規則で必ず拒否する。事前に固定した未知の言い換え60文（間接表現・否定・ひらがな・英語・無関係な依頼を含む）で、v3.3のTF-IDF 31/60（危険な誤受理2）→ 55/60（危険な誤受理0）。

2.4 現場の人への状況報告

判断が確定した後に、VLMが日本語1文で「台の上に何があり、火や煙が見えるか」を報告する（例：「灰色の台には赤い十字の箱が置かれ、その横に炎と煙が立ち上っている。」）。判断ロジックは報告文を読まない（コードとテストで保証）。

2.5 開発データと評価データの分離（事前登録）

プロンプト・閾値・モデルは開発用データ（視点・照明・妨害物・火災をランダム化した画像176枚、指示文40文）だけで決め、評価前に条件をexperiments/PREREGISTRATION_v34.md に固定してから閉ループ評価を一度だけ実行した。失敗・中断した評価も台帳から削除していない。

3. ロボットの振る舞いと安全設計

- 現地確認：到着後、拠点中心へカメラを向けて停止し、オドメトリで静止を確認してから新しいカメラ画像を2枚取得（画質・ROS時刻・シミュレーション時計を検査）。推論中・拒否後もゼロ速度と静止を監視し続ける。
- 回復探索：依頼物資が無い／違う（危険なし）ときだけ、もう一方の拠点で同じ確認を1回行い、確認できたときだけ避難所Bへ。火災・確信度不足・2回目の拒否は停止して人に委ねる。
- 横から見直す（v3.6）：正面の確認で許可したら、拠点の左右0.4 mへ移動して照準・静止確認・新しい画像の取得・判定をやり直す。どちらかで危険を見れば、探索せず危険で停止する（横からの物資判定は使わない）。物資の陰に隠れた火は、視点を変えると見える。
- 独立速度ガード：ミッションは速度を要求するだけで、/cmd_vel の唯一の発行者は別プロセスのガード。センサー鮮度・前方距離・速度上限を10 Hzで判定し異常はラッチ停止。DDSグラフで第2の発行者を検知したら非常停止。
- 真値による監査：成功・停止は、独立レコーダが記録した Gazebo真値姿勢・ROS bag・時系列で判定する。回復探索は「最初の拒否の再計算 → 停止保持 → 探索 → 別拠点での新しい判断」の順序と画像ハッシュまで監査する。

4. 評価結果

4.1 事前登録した閉ループ評価D（v3.4）

試行ごとに Gazebo・ブリッジ・ガード・VLMを新規起動し、42試行を事前に決めた順序で実行した。期待どおりの行動 42/42、誤許可 0 件、指示文の解釈 42/42 正解、判断遅延（静止画取得→判断）中央値 3.06 秒（最大 6.64 秒）。VLM判断前のインフラ失敗による再試行 2 件（台帳に記録）。同じワールドの反復であり、独立なシーン数ではない点に注意。

シナリオ	期待する行動	試行	期待どおり	実際の行動
正常配置	配達	10	10/10	配達 10
物資の取り違え	別拠点を探索して配達	10	10/10	探索して配達 10
欠品（両拠点とも空）	両拠点で確認して停止	10	10/10	停止（物資なし） 10
拠点の裏で火災	探索せず即停止	6	6/6	停止（危険） 6
夕方の暗い照明	配達	4	4/4	配達 4
空の台に段ボール箱	停止	2	2/2	停止（物資なし） 2

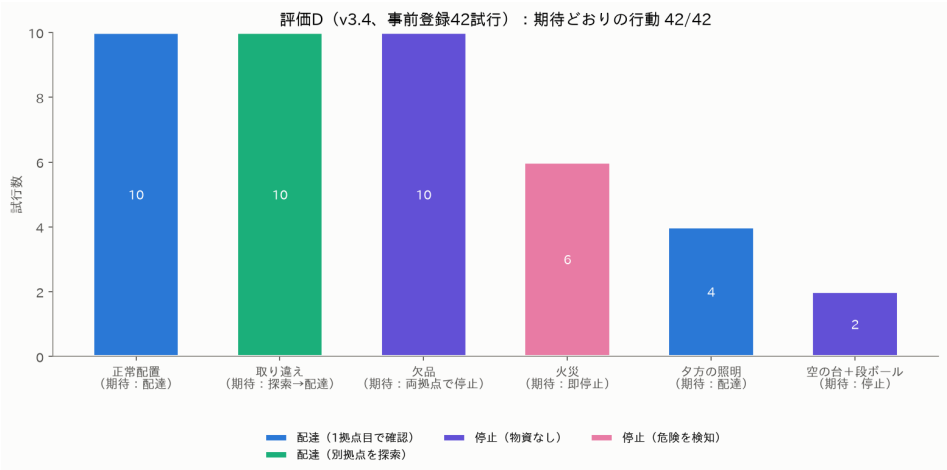


図3 評価Dのシナリオ別結果。

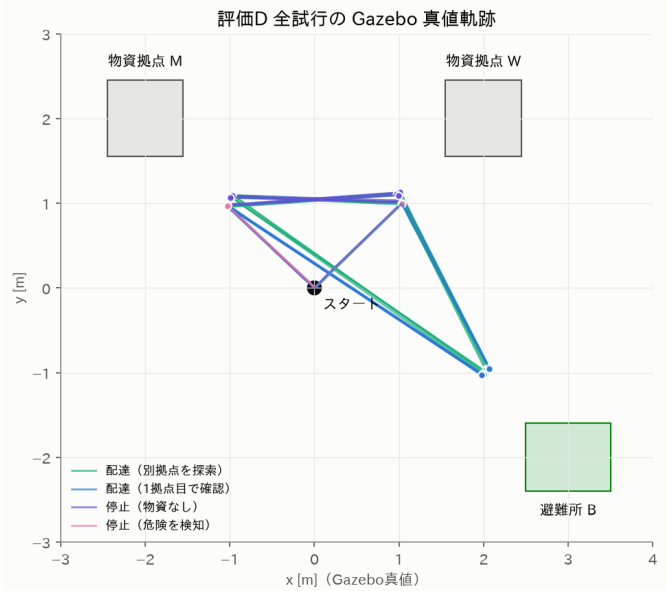


図4 評価D全試行のGazebo真値軌跡。取り違えでは別拠点を経由して避難所へ、欠品・火災では拠点で停止している。

参考：v3.3（評価C、30試行、Qwen2.5-VL-3B、回復探索なし）は VLM判断 30/30・監査まで合格 28/30。取り違えシーンでは「停止」が正解であり、正しい物資を届けることはできなかった。

4.2 評価E（v3.5）：試行ごとにランダムな世界での事前登録評価

照明・小道具の配置・妨害物・火災をランダム化した世界を試行ごとに生成し、60試行を事前に決めた順序で実行した（experiments/campaign_e_protocol.json）。期待どおりの行動 60/60、誤許可 0 件、判断遅延の中央値 3.53 秒。VLM判断前のインフラ失敗による再試行 1 件は台帳に記録（集計は最終試行のみ）。Wilson 95%区間は試行数が少ないため広い（全体の下限 94 %）。

期待する行動	条件	試行	期待どおり	Wilson 95%区間
配達	通常	12	12/12	76–100 %
配達	木箱の妨害物	2	2/2	34–100 %
配達	段ボール箱	2	2/2	34–100 %
配達	コーン	4	4/4	51–100 %
探索して配達	通常	12	12/12	76–100 %
探索して配達	木箱の妨害物	2	2/2	34–100 %
探索して配達	段ボール箱	2	2/2	34–100 %
停止（物資なし）	通常	6	6/6	61–100 %
停止（物資なし）	木箱の妨害物	4	4/4	51–100 %
停止（物資なし）	段ボール箱	2	2/2	34–100 %
停止（危険）	拠点で火災	8	8/8	68–100 %
探索後に危険で停止	別拠点で火災	4	4/4	51–100 %
全体		60	60/60	94–100 %
反事実：盲目的に配達	常に配達（確認しない）	60	20/60（誤行動 40）	23–46 %
反事実：回復探索なし	最初の拒否で停止	60	20/60	23–46 %

反事実は同じ試行に対する計算上の基準で、実行したものではない。盲目的な配達は期待行動が配達（ALLOW）以外の全試行で誤り、回復探索なしは ALLOW の試行のみ成功とみなす保守的な定義（停止が正解の試行も成功に数えない）。

4.3 未使用の画像600枚（T1）での評価

モデル選定・閾値決定に一度も使っていない600枚（描画前に experiments/PREREGISTRATION_T1.md で登録）。拒否すべき画像（408枚）での誤許可、許可すべき画像（191枚）での正しい許可、見えている火（76枚）の検出数を示す。τ_h は登録した主設定 0.5 と、事前指定の副設定 0.05（v3.5）。

方式	誤許可	正しい許可	火の検出	τ_h=0.05：誤許可	正しい許可	火の検出
Qwen3.5-9B（採用）	5	187	67	3	187	69
Qwen3.5-4B	9	190	59	4	190	68
Qwen3-VL-8B	4	183	68	4	183	68
Qwen2.5-VL-3B	4	187	68	1	161	75
Qwen3.5-9B・自由JSON生成（v3.2方式）	5	158	-	-	-	-
Qwen2.5-VL-3B・自由JSON生成（v3.2方式）	0	57	-	-	-	-

検出は 判定が危険（p(危険)が閾値以上）となった見える火の数。自由JSON生成では解析不能 または推論失敗 を拒否として数える（3B：148件）。

解釈：物資の確認は、拒否すべき非火災画像 332 枚で誤許可 0 件（Wilson 95%区間 0–1 %）。採用モデルの誤許可 5 件は、すべて物資が正しく火が一部しか見えない画像だった（火の面積 2541–14918 画素、1万画素未満 3/5 件）。見えている火の検出（p(危険)が0.05以上）は、面積1万画素以上で 68/69、1万画素未満で 1/7。残る弱点は、小さく写った・物資の陰に隠れた火の見逃しである（I-11, I-13）。

4.4 v3.6：物資の陰に隠れた小さな火への対策（問い方 → 横から見直す）

4.3で分かった残る弱点（小さく写った・物資の陰の火の見逃し）に対し、結果を見る前に条件を固定して、段階的に3つの手を打った。最終構成 v3.6 はオーケストレータの既定値（Qwen3.5-9B、危険の問い方 h36＋拡大切り出し tiles、τ_h=0.05、横から見直す0.4 m、回復探索・状況報告あり、DDS非同期）で、過去の評価を再現するときは各台帳の stack_args のフラグを明示する。

- 手1（I-11・I-13、開発データのみ）：「小さい・隠れた・端で切れた火や煙」を明示する問い（h36）と拡大切り出し（tiles）。開発データでの誤許可は v3.5 の 46 → 17（/413枚）。Clef-Flash（Jevの役割、ローカル）との2モデル確認はさらに少ないが、V100 1台に同時に載らない（37 GB）ため既定には採用せず、未使用のT2で確認した。
- 評価F（閉ループ、事前登録、対比較）：小さな火が確認時の姿勢から見えていた13世界で、配達してしまった回数は v3.5（A）12/13 → 手1（B）7/13。食い違いは 5:0、McNemar正確検定 p=0.0625で有意ではない。Bが見逃した火は正面から1,120〜8,573画素（7件）しか写らず、p(危険)が火の無い画像と重なるため、閾値の調整では分けられないと判断した（docs/IMPROVEMENT_LOG.md I-14）。
- 手2：I-14 横から見直す（能動知覚）。同じ火は、確認位置から左右に0.4 mずらした視点では4,600〜22,000画素で見えた（開発用の予備走行、マスク画像で確認）。VLMの判定ではなくロボットの視点を変える。

評価G（experiments/PREREGISTRATION_G.md）：新しい24世界を B と C で対にして48試行を実行した。主張は「Cの方が配達してしまう回数が少なく、かつ p<0.05」で、結果を見る前に固定した。

	B：正面のみ（手1）	C：＋横から見直す（v3.6）
3視点（正面・左右0.4 m）のどれかで火が見えた16世界で、火があるのに配達した回数	11/16	1/16
火の無い世界での誤った停止	0/8	0/8
期待どおりの行動	13/24（95%区間 35–72 %）	23/24（80–99 %）
判断遅延の中央値（1回の判定）	4.99 秒	5.62 秒
正常配達1回の所要時間（中央値）	90 秒	122 秒（約 +32 秒）

食い違いは B のみ 10・C のみ 0、McNemar の正確検定で p=0.002。事前登録した主張が成立した。ただしこの16世界の火の多くは設計上、正面からは見えにくい（または見えない）ため、これは「横から見る効果」の測定である。評価の世界は拠点配置が固定でシミュレーションである点、試行数が少なく区間が広い点にも注意。

唯一の見逃し（W19）：火が正面から0画素（完全に隠れる）、横からも最大 2,308 画素と最小で、p(危険)が閾値0.05に届かなかった。限界として明記する。

未使用のT2（オフライン、描画前に事前登録）

構成	誤許可	正しい許可	火の検出（小／大）
v3.5（Qwen3.5-9B、基準）	0/407（95%区間 0.0–0.9 %）	190/193	5/5・71/71
Clef-Flash 単独（課題向けの質問）	0/407（95%区間 0.0–0.9 %）	187/193	5/5・71/71
Clef-Flash＋Qwen3.5-9B（h36＋tiles、規則上の選定）	0/407（95%区間 0.0–0.9 %）	184/193	5/5・71/71

T2では v3.5 でも誤許可が 0/407 と天井で、改善は測れない（判断を分ける画像がない）。T2の役割は、改良が正しい許可を減らさないことと、Jevの役割を担うClef-Flashがローカルで動くことの確認である。Clef-Flash単独は課題向けの質問にすると誤許可 0/407・正しい許可 187/193、1画像あたりの推論は中央値 0.6 秒（V100）。当初のJev要求（通路の安全を問う質問）のままでは物資の存在確率が低く出て、正しい配達の約半分を拒否した（94/193）。判断モデルは質問の書き方に強く依存する。

5. 新規性と追加の検証

ここまでの評価（D・E・F・G・T1・T2）に加えて、記憶（H）、当初計画の2つのAI（J）、CLIP系との比較（Z）、実写画像（P）、カメラ劣化（R）を追加した。結果ファイルがまだ無いものは「評価中」と明記し、数値は書かない。

5.1 出動をまたぐ記憶（I-15）：記憶は提案し、知覚が決める

同じ避難所への補給は繰り返される。前回の出動で見たものを覚えていれば、物資が入れ替わったままの現場で毎回遠回りせずに済む。しかし災害現場は出動のたびに変わり、古い記憶に従うのは危険である。そこで記憶にできることを2つだけに限る（docs/DESIGN_DECISIONS.md D13）。

- 記憶に書くもの：各出動で、ロボット自身が拠点ごとに「見えた物資」と「危険（火・煙）が見えた方向」を追記する。真値は書かない。
- 順序の提案：前回、依頼物資が別の拠点で見えていたら、その拠点を先に訪ねる。行った先でも必ず現物確認する。
- 慎重さの追加：最近火を見た拠点では、すべての視点で危険の閾値 τ_h を 0.05 から 0.01 に下げ、火が見えた側から先に見る。
- 確認は決して減らさない：記憶を理由に、現物確認・横からの見直し・閾値を省いたり緩めたりしない。

命題（安全側への単調性）：同じカメラ画像を見たとき、記憶を使うロボットが配達する場面は、記憶を使わないロボットも配達する場面だけである。記憶を使うことで配達が増えることはなく、同じか減る。理由は、許可が「依頼物資を確認でき、かつ正面・左右のすべての視点で危険が閾値未満」というAND条件であり、記憶は閾値を下げるか確認の順序を変えるだけで、条件を外せないからである。この性質はコードで強制し（apply_memory_caution・peek_hazard）、監査は保存した出力から記憶による判定を再計算する。

比較対象 M1（素朴な記憶）：記憶を信じる。前回その物資を見た拠点では確認と横からの見直しを省いて配達し、前回危険を見た拠点へは行かずに拒否する。速いが、現場が変わると誤配達・火災への配達につながる。M1は評価Hで測るためだけに実装し、既定にはしない。調査した範囲では、出動をまたぐ記憶で「どこを・どれだけ確認するか」を決め、しかも確認を減らさないことを保証する研究は見当たらなかった（ReMEmbR、Embodied-RAG、When Memory Lies 等との関係は docs/IMPROVEMENT_LOG.md I-15）。

事前登録した評価H（experiments/PREREGISTRATION_H.md）：16系列×3出動、世界は出動ごとに照明・小道具・火を引き直す。M0/M1/M2 を同じ世界で対にして比べる。主要な基準は、P1：物資の入れ替わりが続く出動で M2 が M0 より速い（Wilcoxon正確検定）、P2：危険な配達が M2 の方が M1 より少ない（McNemar正確検定）、P3：M2 の危険な配達が M0 以下。3つが揃って初めて「記憶の速さを保ち、危険を増やさない」と主張する。プロトコル（112試行、sha256 先頭16桁 b08876b2d788394c）は最初の試行の前に固定した。
評価H 実行中（事前登録済み）。結果は experiments/results/h_summary.json が生成され次第、本資料に反映する。

5.2 当初計画の2つのAI（Jev役 Clef-Flash＋Qwen）を実機の閉ループで動かす（I-16）

当初計画は「Jev と Qwen の2つのAIで確認する」ことだった。Jev役はCloudflareのClef-Flash判断モデルをローカルで動かして担わせ、T2ではオフラインで評価していたが、ロボットを動かす閉ループでは使っていなかった（I-13）。I-16 では、実機の経路が当初のJev要求（通路の安全を問う質問）を固定で使い、開発データでは正しい配達の約半分しか許可しなかった点を直し、課題向けの質問に切り替えるフラグ（--jev-schema task）を追加した。両方のAIが許可したときだけ許可し、どちらかが危険を見れば止まる。
V100 1台（32 GB）に載る2モデル構成はこの組（Clef-Flash 19 GB＋Qwen3.5-4B 9 GB）だけで、未使用のT2（オフライン）では誤許可 0/407、正しい許可 185/193だった。

独立性についての注意：Clef-Flash のモデルカードは、これが Qwen3.5-9B からの追加学習であると記している。2つのAIは系統を共有しており、独立に開発されたものではない。多様性は追加学習・大きさ・質問の書き方に由来するにとどまり、独立な版でも誤りが相関すること（Knight & Leveson 1986）を踏まえると、2つに分けたことによる安全の上乗せは主張しない（D11, D14）。
評価J 実行待ち（experiments/PREREGISTRATION_J.md：24世界を v3.6（A）と2つのAI（J）で対にして実行）。主要な基準は、P1：V100 1台で失敗なく走る、P2：危険な配達が J は A 以下。

5.3 比較：CLIP系ゼロショット（Z）

「VLMでなくても、CLIP系の画像と文章の類似度（ゼロショット）で同じ確認ができるのでは」という疑問を、experiments/PREREGISTRATION_Z.md で事前登録して検証した。SigLIP（so400m）とCLIP（ViT-L/14）に本システムと同じ判定構造（物資と火災の2段）を与え、閾値は開発データだけで決めた（開発データの正しい許可：SigLIP 360/360、CLIP 1/360）。

方式（T1・T2は未使用の画像）	T1 誤許可	T1 正しい許可	T2 誤許可	T2 正しい許可
本システム（Qwen3.5-9B＋h36＋拡大切り出し）	3/408（0.2–2.1 %）	187/191（94.7–99.2 %）	0/407（0.0–0.9 %）	190/193（95.5–99.5 %）
SigLIP ゼロショット	44/408（8.1–14.2 %）	191/191（98.0–100.0 %）	47/407（8.8–15.0 %）	193/193（98.0–100.0 %）
CLIP ゼロショット	0/408（0.0–0.9 %）	2/191（0.3–3.7 %）	0/407（0.0–0.9 %）	0/193（0.0–1.9 %）

解釈：SigLIPは正しい許可を保つが、拒否すべき画像を T1 で 44/408、T2 で 47/407 許可してしまう（T1の対比較 McNemar正確検定 p=<0.001）。CLIPは誤許可 0 だが、これはほぼ何も許可しないためで（正しい許可 T1 2/191、T2 0/193）、配達ロボットとして使えない。本システムだけが、誤許可を抑えつつ正しい許可を保つ。

5.4 実写画像（P）：シミュレーションの外での火災判定

シミュレーションの画像だけでは「実写で通用するか」が分からない。そこで実写の火災データセット（D-Fire、CC0）から400枚を層別に抽出し、凍結したv3.6の危険の問い（h36＋拡大切り出し、τ_h=0.05）をそのまま当てた（experiments/PREREGISTRATION_P.md、推論の前に登録）。火・煙のある画像の検出 298/300（95%区間 98–100 %）、火も煙も無い画像の誤警報 64/100（95%区間 54–73 %）。

画像の種類	危険と判定 ／ 枚数
煙のみ	99/100
炎のみ	99/100
炎と煙	100/100
火も煙も無い（誤警報）	64/100
火・煙の面積の三分位（検出）	小（画面の1.6 %未満）98/100、中 100/100、大（22 %以上）100/100

解釈と含意：見逃しはほぼ無い（小さな火・煙も検出）が、火の無い画像の 64/100 を危険と判定した。誤警報の多くは、霞・低い雲・レンズの汚れ・夕焼け・光るテントなどの紛らわしい画像である。つまり安全側に倒れている代わりに、現場ごとの較正なしでは停止が多すぎる。シミュレーションで固定した閾値をそのまま実写へ持ち込むべきではない。

追試P2は評価中：現場での較正（火の無い現地画像で閾値を決める手順）が、較正に使っていない画像で通用するかを事前登録した（experiments/PREREGISTRATION_P2.md、修正1：較正画像は訓練分割の9シャード全体から抽出）。結果は experiments/results/p2_summary.json に出力される。

5.5 カメラ劣化（R）：実機カメラに近づけたとき、失敗は「停止」に倒れるか

Gazeboの画像は雑音がなく鮮明で、露出も適正である。実機のカメラはそうではない。未使用のT2画像（30世界）に、6種類の劣化（センサー雑音、動きぶれ、ピンぼけ、露出不足、露出過多、JPEG劣化）を2段階ずつ（計12条件）加え、v3.6の確認がフェイルクローズ（誤りが停止になり、誤った許可にならない）のままかを調べる（experiments/PREREGISTRATION_R.md。閾値・問いは変更しない）。

評価中（結果は experiments/results/r_summary.json に出力される）。

5.6 事前登録した研究の一覧

どの研究も、結果を見る前に条件・基準・解析を experiments/PREREGISTRATION_<記号>.md に固定した。失敗した試行も台帳に残している。

研究	問い	登録文書	結果
D（v3.4）	閉ループ42試行で期待どおりに動くか	v34	42/42、誤許可 0
E（v3.5）	ランダムな世界で回復探索は効くか	E	60/60、誤配達 0
T1	未使用の画像での誤許可	T1	誤許可 5/408
F・G	横から見直すと小さな火への配達が減るか	G	G：配達 11 → 1（p=0.002）
T2	未使用の画像で改良が悪化しないか	T2	誤許可 0/407、正しい許可 190/193
Z	CLIP系ゼロショットでも足りるか	Z	T1誤許可：本システム 3、SigLIP 44
P	実写の火災画像で通用するか	P	検出 298/300、誤警報 64/100
P2	現場での較正で実写の誤警報が減るか	P2	評価中
R	カメラ劣化でもフェイルクローズか	R	評価中
H	記憶で速くなり、危険は増えないか	H	評価H 実行中
J	2つのAIが実機の閉ループで動くか	J	評価J 実行待ち

6. 改善の軌跡（v3.3 → v3.6）

審査基準（創造性・技術力・実用性・表現力）に沿って自己レビューし、弱点ごとに改善項目を立て、すべて「仮説 → 変更 → 計測（Before/After）」で記録した（docs/REVIEW_AND_PLAN.md、docs/IMPROVEMENT_LOG.md、コミットは git log --grep I-0 で追跡可能）。

ID	弱点・動機	改善	Before → After（計測）
I-01	推測航法のずれで監査不合格	原因を切り分け：DARTの円柱接触の多角形近似 → 球コリジョン	位置誤差 0.160 → 0.011 m
I-02	物資が違うと止まるだけ	別拠点の探索と回復（危険時は探さない）	取り違え：停止 → 探索して配達
I-03	拒否理由が人に伝わらない	判断後の日本語状況報告（判断には不使用）	説明の正確さ 84 → 125/128
I-04	指示理解が合成40文のTF-IDF	ローカルLLMの選択式解釈＋規則ガード	未知の60文 31 → 55/60（危険な誤受理 2 → 0）
I-05	照明・妨害物・火災で未検証	環境ランダム化の開発セットとプロンプト改良	169/176（誤許可6）→ 176/176（誤許可0）
I-06	新機能が未評価	事前登録した42試行の閉ループ評価	42/42（誤許可0）
I-08	モデルが古く研究用途限定	最新世代の調査・公平比較 → Qwen3.5-9B	説明 84→125、指示 50→55/60、誤許可0維持
I-09	停止中の一瞬の途絶で中止（評価Dの再試行2件）	計測で原因を切り分け、停止中の途絶は0を保持（動作中は従来どおり即停止）	停止注入の再現：旧 0/2 完了 → 新 2/2 完了
I-10	探索先の火災を見逃して配達（予備走行、火が物資の陰に隠れる）	危険の閾値を非対称に（見逃しは致命的、誤警報は停止で済む）：τ_h 0.5 → 0.05	予備走行 8/9 → 9/9。T1の誤許可 5 → 3
I-11	小さく写った火の見逃し（T1の誤許可は全てこれ）	小さい・隠れた・端で切れた火や煙を明示した質問（h36）＋拡大切り出し（tiles）。開発データのみで選定	開発データ（火の無い画像を含む413枚）の誤許可 46 → 17、見える火211枚のうち止めた数 165 → 194、正しい許可 357 → 357/360
I-12	送信停止の根本原因（評価Eで再計測）	DDSを非同期送信に（交互A/B/C、AIは不使用）	publishが0.27秒超ブロックした回：同期 5/10 → 非同期 0/10
I-13	当初計画の「2つのAIで確認」から縮退していた	Clef-Flash（Jevの役割、ローカル）をQwenと併用。選定規則は結果前に固定	開発データで誤許可 17 → 15（併用は 37 GB でV100 1台に載らず、既定には採用せず）

ID	弱点・動機	改善	Before → After（計測）
I-14	正面からは物資の陰で見えない小さな火で、それでも配達（評価F）	許可の直前に拠点の左右へ移動して撮り直す（横から見直す）。VLMの閾値では分離できなかった	評価G：火が見える16世界で配達 11 → 1（McNemar正確検定 p=0.002）、火の無い世界の誤停止 0/8

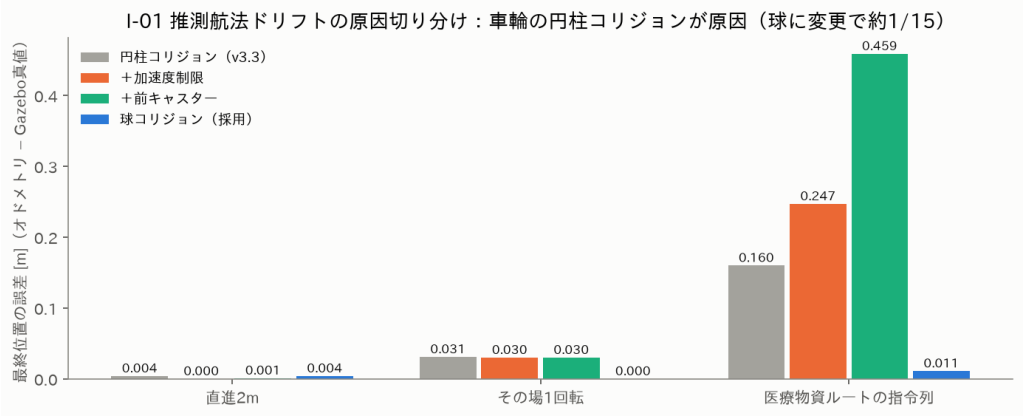


図5 I-01 推測航法ドリフトの原因切り分け（棄却した仮説も含む）。

7. 実際に動かして初めて分かった問題（v3.2引継ぎ → v3.3）

引継ぎ時点のコードは506件の単体テストに合格していたが、実Gazebo・実ROS 2・実GPUでは一度も動いていなかった。実行して（v3.3〜v3.6の開発と評価準備を含め）21件の問題を発見し、すべて再現→修正→確認した（docs/FINDINGS.md）。代表例：

- 車輪軸の定義誤り：オドメトリ上は1.1 m前進、実際の車体は0.15 m（→ Gazebo真値による監査を新設）
- Best Effort QoS で 0.9 MB の画像が102枚中10枚しか届かない（→ Reliable に統一）
- gpu_lidar が自機のカメラマスト（visual）を障害物として検出（→ 可視性マスク）
- 評価の中断時に孤立したスタックが別試行に速度指令を出し続けた（→ 段階的停止と起動前の孤立スタック検出。Publisher監視は正しく検知していた）

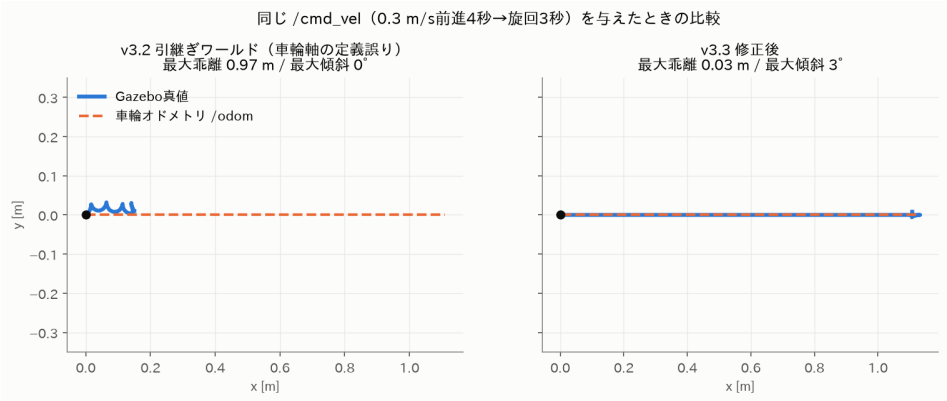


図6 同じ速度指令に対する車輪オドメトリとGazebo真値（左：引継ぎ版、右：修正後）。

8. 実用性・応用可能性

- 在庫と現物のずれに強い：物流倉庫・病院内搬送・避難所運営で、誤った物資を届けず、無ければ探し、それでも無ければ人に報告して止まる。
- オフライン・オンデバイス：通信途絶を想定し、推論はすべて単一GPU上（APIキー不要、Apache-2.0のモデル）。
- 説明と検証可能性：判断画像のハッシュ・各質問の確率・日本語報告・真値軌跡・ROS bagを試行ごとに保存し、第三者が判断と行動の因果を再計算できる。

9. 限界と今後の課題

- v3.6の横から見直す効果（評価G）は、拠点配置が固定の新しい世界での対比較で、試行数は少ない。完全に隠れた火は横からも見逃し得る。実機・実写では未検証。

- 物資の把持・運搬は未実装。Nav2の動的経路計画ではなく既知配置のウェイポイント追従。
- 小道具は単純形状、拠点は2か所・避難所は1か所の固定配置。実機（SO-101等）でのSim-to-Realは未検証。実写画像で検証したのは火災判定のみ（5.4章）で、物資の確認と閉ループは実写では未検証。
- 閾値（τ_s=0.50、τ_h=0.05）は確率の較正ではない。開発データでは余裕が大きいが、分布の異なる環境では再評価が必要。
- ROSグラフ監視は認証機構ではなく、実機の安全認証を意味しない。

10. 提出動画の構成

全 2:46。3-D映像はすべてGazeboの実レンダリング（俯瞰カメラ＋ロボット搭載カメラ）で、模式図やモック映像は使っていない。字幕・確率バー・軌跡・ロボットの報告文はその試行のログから自動合成。走行8倍速・確認動作3倍速・AI判断の瞬間は等速で、速度は画面左上に常時表示している。ナレーションは VOICEVOX:四国めたん。

時刻	内容	備考
0:00–0:06	RescueMind	
0:06–0:32	デモ1：言い換えた指示でも配達	走行8倍速・確認動作3倍速・AI判断の瞬間は等速（run dbed92419f88479e）
0:32–1:10	デモ2：取り違え → 別拠点を探索	走行8倍速・確認動作3倍速・AI判断の瞬間は等速（run b4fcd9d164444db7）
1:10–1:35	デモ3：欠品 → 両拠点を確認して停止	走行8倍速・確認動作3倍速・AI判断の瞬間は等速（run 367928c988f34e34）
1:35–1:56	デモ4：隠れた小さな火 → 停止	走行8倍速・確認動作3倍速・AI判断の瞬間は等速（run 9d73663832c94f16）
1:56–2:06	事前登録60試行：期待どおり 60/60・誤配達 0件	
2:06–2:15	未使用600枚（T1）：誤許可と正しい許可	
2:15–2:39	残る弱点への対策（v3.6）	
2:39–2:45	RescueMind	

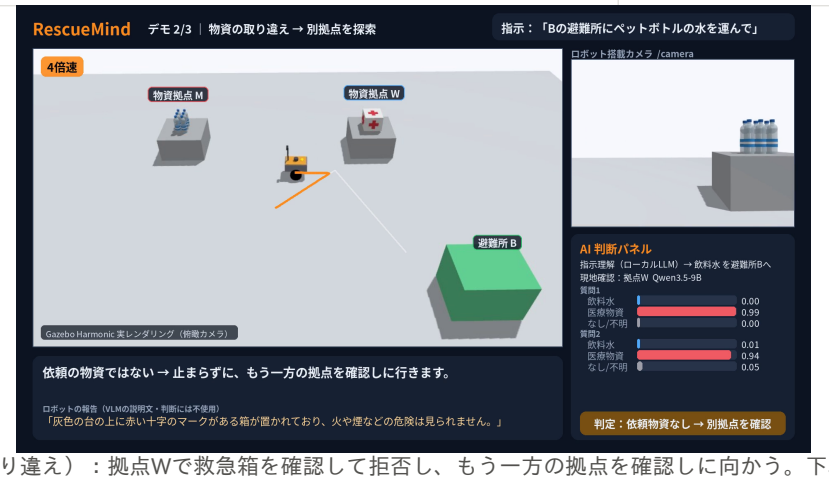


図7 動画の一場面（取り違え）：拠点Wで救急箱を確認して拒否し、もう一方の拠点を確認しに向かう。下段はロボットの日本語報告。

11. 再現方法

bash docker/build.sh → bash docker/run.sh python3 scripts/run_campaign.py --protocol experiments/campaign_e_protocol.json（v3.6 の構成が既定値。過去の評価の再現は各台帳の stack_args を明示）。全体フローは docs/ARCHITECTURE.md、設計判断は docs/DESIGN_DECISIONS.md。

本資料・動画・コードに氏名・所属・メールアドレス等の個人情報は含めていない。講座サンプル（差動二輪ROSシミュレーション等）を出発点に、現地VLM確認・回復探索・独立安全ガード・真値監査・事前登録評価を独自に設計・実装した。